

Scénarios Métier - Projet Data Quality

NYC Taxi Dataset

Ce document présente les deux scénarios métier sélectionnés pour l'analyse de qualité des données du dataset NYC Taxi, avec identification des attributs critiques et dimensions de qualité prioritaires pour chaque cas d'usage.

Scénario 1 : Chauffeur de Taxi - Déclaration Fiscale

Objectif :

Déclarer ses revenus aux autorités fiscales de manière exacte, traçable et conforme aux exigences légales.

Attributs CRITIQUES (par ordre d'importance) :

#	Attribut	Criticité	Justification
1	fare_amount	■ CRITIQUE	Montant exact des revenus à déclarer
2	pickup_datetime	■ CRITIQUE	Preuve de la date de course (période fiscale)
3	dropoff_datetime	■ CRITIQUE	Calcul de la durée de travail
4	payment_type	■ CRITIQUE	Distinction espèces/carte (traçabilité fiscale)
5	trip_distance_miles	■ IMPORTANT	Justification des frais kilométriques déductibles

Attributs SECONDAIRES :

- **passenger_count** ■ - Non pertinent pour les déclarations fiscales
- **Coordonnées GPS (pickup/dropoff lat/lon)** ■ - Non nécessaires pour l'administration fiscale

Dimensions de Qualité Prioritaires :

Dimension	Priorité	Impact
Completeness	■ HAUTE	Aucune course manquante = perte de revenus déclarés
Accuracy	■ HAUTE	Montants et dates corrects = pas de redressement fiscal
Timeliness	■ MOYENNE	Dates correctes = bonne période déclarative

Scénario 2 : Passager - Contester une Surfacturation

Objectif :

Prouver que le prix payé ne correspond pas au trajet réellement effectué, afin de contester une surfacturation auprès du service client ou des autorités.

Attributs CRITIQUES (par ordre d'importance) :

#	Attribut	Criticité	Justification
1	fare_amount	■ CRITIQUE	Montant du prix contesté
2	trip_distance_miles	■ CRITIQUE	Distance réelle vs distance facturée
3	pickup_latitude/longitude	■ CRITIQUE	Point de départ exact du trajet
4	dropoff_latitude/longitude	■ CRITIQUE	Point d'arrivée exact du trajet
5	pickup_datetime	■ IMPORTANT	Heure de la course (tarif jour/nuit différent)

Attributs SECONDAIRES :

- **dropoff_datetime** ■ - Peut servir à prouver un détour suspect
- **passenger_count** ■ - Non pertinent pour la contestation
- **payment_type** ■ - Non pertinent pour prouver la surfacturation

Dimensions de Qualité Prioritaires :

Dimension	Priorité	Impact
Accuracy	■ HAUTE	Distance et prix doivent être exacts pour prouver l'arnaque
Consistency	■ HAUTE	Distance cohérente avec coordonnées GPS
Relevance	■ MOYENNE	Information suffisante pour monter un dossier de contestation

Résumé Comparatif des Scénarios

Attribut	Chauffeur (Fiscal)	Passager (Contestation)
fare_amount	■ CRITIQUE	■ CRITIQUE
pickup_datetime	■ CRITIQUE	■ IMPORTANT
dropoff_datetime	■ CRITIQUE	■ SECONDAIRE
trip_distance_miles	■ IMPORTANT	■ CRITIQUE
pickup_latitude/longitude	■ INUTILE	■ CRITIQUE
dropoff_latitude/longitude	■ INUTILE	■ CRITIQUE
payment_type	■ CRITIQUE	■ INUTILE
passenger_count	■ INUTILE	■ INUTILE

Impact Différencié :

Observation clé : Les coordonnées GPS (pickup/dropoff latitude/longitude) sont **critiques pour le passager** (preuve du trajet réel pour contester) mais **inutiles pour le chauffeur** (non requises pour la déclaration fiscale).

À l'inverse, le **payment_type** est **critique pour le chauffeur** (distinction espèces/carte pour la traçabilité fiscale) mais **non pertinent pour le passager** (qui veut juste prouver une surfacturation).

Implication pour l'analyse de qualité : La gravité d'une erreur dépend du scénario d'usage (fitness for use). Une même erreur peut être critique dans un contexte et négligeable dans un autre.